

Programação de Algoritmos de Compressão e Análise de Imagens

Relatório do Trabalho Prático 2

Enzo Borges Segala, Jonathan Gabriel Nunes Mendes, Matheus Machado Cezar,
Marcos Henrique Volpato de Moraes, Miguel Predebon Abichequer, Nicolas Rosenthal
Dal Corso, and Rafael Silveira Bandeira

Universidade Federal do Rio Grande do Sul

09/12/2025

Sumário

1	Compressão baseada no modo básico do JPEG	3
1.1	Metodologia	3
1.1.1	Preparação da imagem	3
1.1.2	Discrete Cosine Transform (DCT)	3
1.1.3	Quantização	3
1.1.4	Reconstrução (Descompressão)	3
1.1.5	Cálculo das métricas	3
1.2	Código	4
1.3	Resultados Obtidos	7
1.3.1	Imagens originais	7
1.3.2	Imagens resultantes	8
1.4	Análise dos Resultados	9
2	Compressão baseada na quantização vetorial	11
2.1	Metodologia	11
2.1.1	Formação dos blocos	11
2.1.2	Construção do Codebook (K-Means)	11
2.1.3	Compressão	11
2.1.4	Reconstrução	11
2.1.5	Métricas	11
2.2	Código	11
2.3	Resultados Obtidos	15
2.3.1	Imagens originais	15
2.3.2	Imagens resultantes	16
2.4	Análise dos Resultados	19
3	Segmentação	20
3.1	Metodologia	20
3.1.1	Segmentação por K-means no Espaço de Cor Lab	20
3.1.2	Segmentação baseada em Textura com Filtros de Gabor	20
3.2	Código	20
3.3	Resultados Obtidos e Análise	28
3.3.1	Imagens originais	29
3.3.2	Cachorro K-Means	30
3.3.3	Cachorro Gabor + K-Means	31
3.3.4	Costa K-Means	32
3.3.5	Costa Gabor + K-Means	33
3.4	Conclusão da Análise	34
	Siglas	35

1 Compressão baseada no modo básico do JPEG

Nesta etapa do trabalho foi implementada uma versão simplificada do método JPEG baseline, mantendo as operações essenciais do algoritmo, porém sem utilizar a etapa de codificação entrópica (Run-Length Encoding e codificação de Huffman). O objetivo é analisar o comportamento da compressão apenas com as etapas de transformação, quantização e reconstrução.

1.1 Metodologia

A compressão foi aplicada a duas imagens em tons de cinza selecionadas previamente. O método adotado segue a lógica do JPEG básico, composta pelas seguintes etapas:

1.1.1 Preparação da imagem

A imagem original é convertida para valores do tipo double e, caso suas dimensões não sejam múltiplas de 8, aplica-se padding replicando os valores da borda. Isso garante que a imagem possa ser dividida integralmente em blocos de 8×8 pixels, tamanho padrão do JPEG.

1.1.2 Discrete Cosine Transform (DCT)

Após a divisão em blocos, é aplicada a DCT bidimensional em cada bloco. Essa transformada converte a informação espacial da imagem em componentes de frequência, concentrando grande parte da energia nos primeiros coeficientes.

1.1.3 Quantização

Cada bloco transformado é quantizado utilizando uma matriz de quantização padrão do JPEG, escalada por um fator Q , que controla a intensidade da compressão. Valores maiores de Q provocam quantização mais agressiva e, portanto, maior perda de informação e maior taxa de compressão.

1.1.4 Reconstrução (Descompressão)

Para reconstruir a imagem comprimida, os coeficientes quantizados são de-quantizados (multiplicação pela matriz), e a Inverse Discrete Cosine Transform (IDCT) é aplicada aos blocos, retornando ao domínio espacial.

1.1.5 Cálculo das métricas

Dois indicadores foram utilizados para avaliar os resultados:

- **Taxa de compressão:** estimada considerando a proporção entre o número total de coeficientes e o número de coeficientes não nulos após a quantização.
- **Peak Signal-to-Noise Ratio (PSNR):** mede a similaridade entre a imagem original e a reconstruída; valores maiores indicam menor perda de qualidade.

1.2 Código

```
function [rec_img, ratio, psnr_val] = jpeg_basic(img, Q)

    img = double(img);
    [h, w] = size(img);

    % Ajustar dimensões para múltiplos de 8
    H = ceil(h/8) * 8;
    W = ceil(w/8) * 8;

    padded = padarray(img, [H-h W-w], 'replicate', 'post');

    % Matriz de quantização base do JPEG
    Qbase = [16 11 10 16 24 40 51 61;
              12 12 14 19 26 58 60 55;
              14 13 16 24 40 57 69 56;
              14 17 22 29 51 87 80 62;
              18 22 37 56 68 109 103 77;
              24 35 55 64 81 104 113 92;
              49 64 78 87 103 121 120 101;
              72 92 95 98 112 100 103 99];

    Qmatrix = Q * Qbase;

    coeffs = zeros(H,W);

    % --- Compressão: DCT + Quantização ---
    for i = 1:8:H
        for j = 1:8:W
            bloco = padded(i:i+7, j:j+7);
            D = dct2(bloco);
            C = round(D ./ Qmatrix);
            coeffs(i:i+7, j:j+7) = C;
        end
    end

    % Estimar taxa de compressão
    total = numel(coeffs);
    nzeros = nnz(coeffs);
    ratio = total / nzeros;

    % --- Descompressão ---
    rec = zeros(H,W);
    for i = 1:8:H
        for j = 1:8:W
            C = coeffs(i:i+7, j:j+7);
```

```

        D = C .* Qmatrix;
        rec(i:i+7, j:j+7) = idct2(D);
    end
end

rec_img = rec(1:h, 1:w);

% --- PSNR ---
mse = mean((img(:) - rec_img(:)).^2);
psnr_val = 10 * log10(255^2 / mse);

end

warning('off', 'MATLAB:MKDIR:DirectoryExists'); % i know it may exists
mkdir('.out');

% Carregar imagens em tons de cinza
img1 = imread('borboleta.jpg');
img2 = imread('raposa.jpg');

if size(img1, 3) == 3
    img1 = rgb2gray(img1);
end

if size(img2, 3) == 3
    img2 = rgb2gray(img2);
end

% Valores de Q para teste
Qvalues = [2 4 8 16];

% =====
%   MOSTRAR APENAS UMA FIGURA COM AS DUAS IMAGENS ORIGINAIS
% =====
figure('Name', 'Imagens Originais', 'NumberTitle', 'off');
subplot(1, 2, 1);
imshow(uint8(img1));
title('Imagem 1 - Original (P&B)');

subplot(1, 2, 2);
imshow(uint8(img2));
title('Imagem 2 - Original (P&B)');

% =====
%   PROCESSAR E ARMAZENAR OS RESULTADOS PARA NÃO ABRIR MIL FIGURAS
% =====

```

```

rec_imgs1 = cell(length(Qvalues), 1);
rec_imgs2 = cell(length(Qvalues), 1);

ratios1 = zeros(length(Qvalues), 1);
ratios2 = zeros(length(Qvalues), 1);

psnr1_vals = zeros(length(Qvalues), 1);
psnr2_vals = zeros(length(Qvalues), 1);

for k = 1:length(Qvalues)

    Q = Qvalues(k);
    fprintf('\n== Testando com Q = %d ==\n', Q);

    % Imagem 1
    [rec1, ratio1, psnr1] = jpeg_basic(img1, Q);
    rec_imgs1{k} = rec1;
    ratios1(k) = ratio1;
    psnr1_vals(k) = psnr1;

    fprintf('Imagem 1 - Taxa: %.2f | PSNR: %.2f dB\n', ratio1, psnr1);

    % Imagem 2
    [rec2, ratio2, psnr2] = jpeg_basic(img2, Q);
    rec_imgs2{k} = rec2;
    ratios2(k) = ratio2;
    psnr2_vals(k) = psnr2;

    fprintf('Imagem 2 - Taxa: %.2f | PSNR: %.2f dB\n', ratio2, psnr2);

end

% =====
% MOSTRAR APENAS 1 FIGURA COM AS 4 COMPRESSÕES DA IMAGEM 1
% =====
figure('Name', 'Compressões - Imagem 1', 'NumberTitle', 'off');

for k = 1:length(Qvalues)
    subplot(2, 2, k);
    imshow(uint8(rec_imgs1{k}));
    title(['Q = ' num2str(Qvalues(k)) ...
          ' | PSNR = ' num2str(psnr1_vals(k), '%.2f') ...
          ' | Taxa = ' num2str(ratios1(k), '%.2f')]);
    imwrite(uint8(rec_imgs1{k}), strcat('.out/borboleta_', num2str(
        Qvalues(k)), '.png'));
end

```

```

end

% =====
%  MOSTRAR APENAS 1 FIGURA COM AS 4 COMPRESSÕES DA IMAGEM 2
%  =====
figure('Name', 'Compressões - Imagem 2', 'NumberTitle', 'off');

for k = 1:length(Qvalues)
    subplot(2, 2, k);
    imshow(uint8(rec_imgs2{k}));
    title(['Q = ' num2str(Qvalues(k)) ...
          ' | PSNR = ' num2str(psnr2_vals(k), '%.2f') ...
          ' | Taxa = ' num2str(ratios2(k), '%.2f')]);
    imwrite(uint8(rec_imgs2{k}), strcat('.out/raposa_', num2str(
        Qvalues(k)), '.png'));
end

```

1.3 Resultados Obtidos

A compressão foi aplicada utilizando $Q \in \{2, 4, 8 \text{ e } 16\}$ como o fator de quantização, de modo a observar como o aumento da quantização influencia tanto a taxa de compressão quanto a qualidade final da imagem reconstruída.

1.3.1 Imagens originais



(a) Borboleta



(b) Raposa

Figura 1: Imagens originais

1.3.2 Imagens resultantes

Imagem 1: borboleta.jpg		
Q	Taxa de Compressão	PSNR (dB)
2	11.89	31.95
4	20.82	29.64
8	35.33	27.24
16	52.01	24.42



(a) $Q = 2$



(b) $Q = 4$



(c) $Q = 8$



(d) $Q = 16$

Figura 2: Resultado da aplicação na imagem borboleta

Imagem 2: raposa.jpg		
Q	Taxa de Compressão	PSNR (dB)
2	12.55	29.38
4	20.58	27.80
8	34.36	26.03
16	52.65	23.65




Figura 3: Resultado da aplicação na imagem raposa

1.4 Análise dos Resultados

Os testes realizados mostram claramente a relação entre o fator de quantização e a qualidade final da imagem:

- **Q baixo (ex.: $Q = 2$):** Quando a quantização é fraca, a perda de informação é pequena. As duas imagens apresentaram PSNR acima de 29 dB, indicando boa preservação visual. A taxa de compressão, porém, permanece relativamente modesta (cerca de 12 %).
- **Q intermediário ($Q = 4$ e 8):** À medida que o Q aumenta, mais coeficientes da DCT são aproximados para zero, o que reduz o tamanho dos dados. As taxas aumentam para cerca de 20 % e depois para mais de 30 %, ao custo de uma queda gradual no PSNR. Nessa faixa, os primeiros artefatos típicos do JPEG começam a aparecer, especialmente blocagem em áreas com

pouca textura.

- **Q alto ($Q = 16$):** A compressão torna-se bastante agressiva: as taxas ultrapassam 50 %, ou seja, mais da metade dos coeficientes se tornam nulos. Consequentemente, a qualidade se degrada mais intensamente, com PSNR entre 23 dB e 24 dB, valores que normalmente já representam perda de detalhes e blocos visíveis.

Comparando as duas imagens, nota-se que:

- A **Imagem 1** mantém valores de PSNR ligeiramente superiores em todos os níveis de compressão, sugerindo que sua estrutura visual é mais adequada ao modelo JPEG.
- A **Imagem 2** apresenta queda de qualidade um pouco mais acentuada, indicando sensibilidade maior à quantização, possivelmente por conter áreas suaves ou gradientes que são mais afetados por perdas nas altas frequências.

No geral, os resultados confirmam o comportamento esperado do algoritmo JPEG: **mais compressão** → **mais perda** → **menor PSNR**, com artefatos cada vez mais perceptíveis.

2 Compressão baseada na quantização vetorial

Nesta etapa do trabalho, foi implementada uma técnica de compressão baseada em **quantização vetorial (VQ)**. Esse método consiste em dividir a imagem em blocos de dimensões fixas, agrupar blocos similares por meio do algoritmo **K-Means**, e substituir cada bloco da imagem por um índice que referencia um bloco representativo dentro de um codebook.

O processo foi aplicado a quatro imagens: duas em tons de cinza (**doca** e **cachorro**) e duas coloridas (**borboleta** e **raposa**). Para cada imagem, foram testados dois tamanhos de blocos: 2×2 e 3×3 . Em todos os casos, o codebook é composto por **256 vetores**, conforme solicitado no enunciado.

2.1 Metodologia

O método foi dividido nas seguintes etapas:

2.1.1 Formação dos blocos

A imagem é percorrida em blocos **não sobrepostos**, de tamanho 2×2 ou 3×3 . Cada bloco é convertido em um vetor coluna. No caso de imagens coloridas, esse processo é feito **por canal (R,G,B)**.

2.1.2 Construção do Codebook (K-Means)

Coletamos uma amostra dos blocos da imagem e aplicamos o algoritmo **K-Means** para agrupá-los em 256 grupos. O centro de cada cluster torna-se uma **palavra do codebook**.

2.1.3 Compressão

Cada bloco da imagem é substituído por **um índice inteiro entre 1 e 256**, correspondente ao bloco mais próximo do codebook. A imagem comprimida contém: o codebook e a matriz de índices.

2.1.4 Reconstrução

A imagem é reconstituída substituindo cada índice pelo bloco correspondente no codebook. Para imagens coloridas, a operação é feita separadamente para os três canais.

2.1.5 Métricas

Foram calculados:

- **Taxa de compressão** = bits da imagem original / bits da representação VQ
- **PSNR**, comparando a imagem reconstruída com a original

2.2 Código

```
function [rec_img, ratio, psnr_med] = vq_color(img, B)

    R = img(:,:,1);
    G = img(:,:,2);
```

```

Bc = img(:,:,3);

[recR, rR, pR] = vq_gray(R, B);
[recG, rG, pG] = vq_gray(G, B);
[recB, rB, pB] = vq_gray(Bc, B);

rec_img = cat(3, recR, recG, recB);

ratio = (rR + rG + rB) / 3;
psnr_med = (pR + pG + pB) / 3;

end

function [rec_img, ratio, psnr_val] = vq_gray(img, B)

    img = double(img);

    % GARANTIA DE QUE É CINZA (2D)
    if ndims(img) ~= 2
        img = rgb2gray(uint8(img));
        img = double(img);
    end

    [h, w] = size(img);

    H = ceil(h/B) * B;
    W = ceil(w/B) * B;

    padded = padarray(img, [H-h, W-w], 'replicate', 'post');

    % EXTRAI BLOCOS SEMPRE 2D
    blocks = im2col(padded, [B B], 'distinct');
    N = size(blocks, 1);

    max_samples = 10000;

    if N > max_samples
        idx = randperm(N, max_samples);
        sample_blocks = blocks(idx, :);
    else
        sample_blocks = blocks;
    end

    K = 256;

    [~, codebook] = kmeans(sample_blocks, K);

```

```

D = pdist2(blocks, codebook);
[~, compressed_idx] = min(D, [], 2);

rec_blocks = codebook(compressed_idx, :);
rec_blocks = rec_blocks';

rec_padded = col2im(rec_blocks, [B B], [H W], 'distinct');

rec_img = rec_padded(1:h, 1:w);

bits_original = numel(img) * 8;
bits_codebook = numel(codebook) * 8;
bits_indices = N * 8;

bits_total = bits_codebook + bits_indices;

ratio = bits_original / bits_total;

mse = mean((img(:) - rec_img(:)).^2);
psnr_val = 10 * log10(255^2 / mse);

end

clear all; close all; clc;

gray_imgs = {'./out/doca.png', './out/cachorro.png'};
color_imgs = {'borboleta.jpg', 'raposa.jpg'};

B_values = [2 3];

% IMAGENS EM CINZA
for b = 1:length(B_values)
    B = B_values(b);

    figure('Name', ['Cinza B=' num2str(B)], 'NumberTitle', 'off');

    for i = 1:length(gray_imgs)

        img = imread(gray_imgs{i});

        if ndims(img) == 3
            img = rgb2gray(img);
        end

        img = double(img);
    end
end

```

```

[rec, ratio, psnr_val] = vq_gray(img, B);

disp(['Cinza | ' gray_imgs{i} ...
      ' | B=' num2str(B) ...
      ' | TAXA=' num2str(ratio, '%.2f') ...
      ' | PSNR=' num2str(psnr_val, '%.2f')]);

subplot(2, 2, i);
imshow(uint8(img));

subplot(2, 2, i + 2);
imshow(uint8(rec));

record(gray_imgs{i}, rec, B, ratio, psnr_val)
end

end

% IMAGENS COLORIDAS
for b = 1:length(B_values)
    B = B_values(b);

    figure('Name', ['Coloridas B=' num2str(B)], 'NumberTitle', 'off');

    for i = 1:length(color_imgs)

        img = imread(color_imgs{i});
        img = double(img);

        [rec, ratio, psnr_val] = vq_color(img, B);

        disp(['Color | ' color_imgs{i} ...
              ' | B=' num2str(B) ...
              ' | TAXA=' num2str(ratio, '%.2f') ...
              ' | PSNR=' num2str(psnr_val, '%.2f')]);

        subplot(2, 2, i);
        imshow(uint8(img));

        subplot(2, 2, i + 2);
        imshow(uint8(rec));

        record(color_imgs{i}, rec, B, ratio, psnr_val)
    end
end

```

end

2.3 Resultados Obtidos

Os valores de **taxa de compressão** e **PSNR** obtidos estão apresentados nas tabelas a seguir.

2.3.1 Imagens originais



(a) Doca



(b) Cachorro

Figura 4: Imagens em tons de cinza



(a) Borboleta



(b) Raposa

Figura 5: Imagens coloridas

2.3.2 Imagens resultantes

Imagens em tons de cinza			
Bloco	Imagem	Taxa de Compressão	PSNR (dB)
2×2	doca	3.85	37.69
	cachorro	3.87	39.44
3×3	doca	7.60	33.88
	cachorro	7.64	36.80

Imagens coloridas			
Bloco	Imagem	Taxa de Compressão	PSNR (dB)
2×2	borboleta	3.95	34.45
	raposa	3.96	33.46
3×3	borboleta	8.45	31.01
	raposa	8.59	29.19



(a) Bloco 2×2



(b) Bloco 3×3

Figura 6: Resultado da aplicação na imagem doca



(a) Bloco 2×2



(b) Bloco 3×3

Figura 7: Resultado da aplicação na imagem cachorro



(a) Bloco 2×2



(b) Bloco 3×3

Figura 8: Resultado da aplicação na imagem borboleta



(a) Bloco 2×2

(b) Bloco 3×3

Figura 9: Resultado da aplicação na imagem raposa

2.4 Análise dos Resultados

Os resultados mostram claramente que o tamanho do bloco utilizado na VQ influencia diretamente a qualidade da reconstrução e a taxa de compressão. Com blocos de 2×2 , a imagem é dividida em partes menores e mais detalhadas, o que permite uma representação mais precisa pelos vetores do codebook. Por isso, as reconstruções apresentam valores de PSNR mais altos, indicando melhor qualidade visual, embora a taxa de compressão seja menor.

Quando blocos de 3×3 são utilizados, ocorre o inverso: como a imagem passa a ter menos blocos, a quantidade total de índices diminui e a taxa de compressão aumenta. No entanto, blocos maiores costumam reunir regiões com mais variação interna, o que prejudica a fidelidade da reconstrução e reduz o PSNR. Assim, confirma-se o trade-off esperado: blocos menores preservam a qualidade, enquanto blocos maiores privilegiam a compressão.

Ao comparar imagens em tons de cinza com imagens coloridas, nota-se que as coloridas apresentam PSNR um pouco menor. Isso acontece porque cada canal (R, G e B) é quantizado separadamente, e as pequenas perdas de cada componente acabam se somando no resultado final. Mesmo assim, as taxas de compressão obtidas foram semelhantes às das imagens em cinza.

Em resumo, os experimentos mostram exatamente o comportamento previsto pela teoria da VQ: blocos menores resultam em maior qualidade reconstruída, enquanto blocos maiores aumentam a compressão, porém com maior perda visual.

3 Segmentação

Nesta etapa do trabalho, foram implementados dois métodos distintos de segmentação aplicados a duas imagens coloridas. O objetivo é comparar abordagens baseadas em diferentes princípios: uma fundamentada exclusivamente em agrupamento no espaço de cores, e outra que utiliza propriedades de textura, incorporando informações adicionais sobre padrões locais da imagem.

A segmentação é uma tarefa fundamental no processamento de imagens, pois permite dividir a imagem em regiões homogêneas que representam objetos, fundos ou áreas de interesse. Neste trabalho, optou-se por métodos que produzem resultados estruturados e que seguem diretamente o que foi solicitado pelo enunciado: um método baseado em agrupamento (k-means) e um método que utilize textura.

Além disso, em ambos os métodos foram testados **diferentes valores de K**, permitindo avaliar como a granularidade da segmentação influencia a qualidade e o nível de detalhamento obtido.

3.1 Metodologia

A metodologia foi organizada em duas abordagens independentes, cada uma avaliada com três valores distintos de K (2, 3 e 4).

3.1.1 Segmentação por K-means no Espaço de Cor Lab

A imagem é inicialmente convertida do espaço RGB para o espaço Lab, que separa a luminância dos componentes cromáticos e melhora a distinção entre cores semelhantes. Cada pixel é representado pelo vetor (L, a, b) e todos os pixels são reunidos em uma matriz de características.

Em seguida, aplicam-se sucessivamente diferentes valores de K no algoritmo K-means, produzindo segmentações com níveis variados de separação entre regiões. Cada resultado é reorganizado no formato da imagem original, gerando mapas de clusters com diferentes granularidades.

Esse método utiliza apenas a cor como critério de separação, sendo eficaz para segmentar objetos visualmente distintos ou regiões com tonalidades marcadas.

3.1.2 Segmentação baseada em Textura com Filtros de Gabor

Para incorporar informações de textura, utiliza-se um conjunto de filtros de Gabor com múltiplas orientações e frequências espaciais. Essas respostas são capazes de detectar padrões repetitivos e estruturas locais como bordas, rugosidade e variações de orientação.

Após converter a imagem para tons de cinza, cada filtro é aplicado e gera um mapa de textura. Os valores de resposta são vetorizados, normalizados e utilizados como entrada para o algoritmo K-means. Assim como no método anterior, diferentes valores de K são testados (2, 3 e 4), resultando em segmentações mais grossas ou mais detalhadas.

Esse método é capaz de separar regiões que possuem texturas distintas mesmo quando têm cores semelhantes, sendo complementar à segmentação baseada somente em cor.

3.2 Código

```

function seg = segment_kmeans(img, K)
    img = im2double(img);

    % converter para Lab
    cform = makecform('srgb2lab');
    lab = applycform(img, cform);

    % reorganizar pixels
    X = reshape(lab, [], 3);

    % k-means
    idx = kmeans(X, K, 'MaxIter', 1000);
    % idx = kmeans(X, K);

    % voltar para imagem
    seg = reshape(idx, size(img,1), size(img,2));

end

function seg = segment_gabor(img, K)
    [H, W, ~] = size(img);
    img = im2double(img);
    gray = img;

    if (ndims(img) == 3)
        gray = rgb2gray(img);
    end

    wavelengths = [3 6 12 24];
    orientations = [0 45 90 135];
    g = gaborCombinations(wavelengths, orientations, 1, 4);

    [gabormag, ~] = gaborFFT(gray, g);
    seg = segkmeans(gabormag, K, H, W);

end

function featureSet = makeFeatureSet(H, W, magnitudes)
    [X_map, Y_map] = meshgrid(1:W, 1:H);
    featureSet = cat(3, magnitudes, X_map, Y_map); % Big cube
    S = size(featureSet);
    featureSet = reshape(zscore(reshape(featureSet, [], S(3))), S);

end

function Label = segkmeans(magnitudes, K, H, W)
    I = makeFeatureSet(H, W, magnitudes);
    [m, n, ~] = size(I);

```

```

X = reshape(I, m * n, []);
Label = kmeans(zscore(X), K, 'MaxIter', 1000);
% Label = kmeans(zscore(X), K);
Label = reshape(Label, H, W);
end

function resultsOut = gaborCombinations(lambda, theta, bandwidth,
spatialAspectRatio)
[lambda, theta, bandwidth, spatialAspectRatio] = ...
    ndgrid(lambda, theta, bandwidth, spatialAspectRatio);

lambda = lambda(:);
theta = theta(:);
bandwidth = bandwidth(:);
spatialAspectRatio = spatialAspectRatio(:);

s = ones(1, size(lambda, 1));

X = lambda / pi * sqrt(log(2) / 2) .* ...
    (2 .^ bandwidth + 1) ./ ...
    (2 .^ bandwidth - 1);
sigma = [X, X ./ spatialAspectRatio];

resultsOut = struct( ...
    'Wavelength', mat2cell(lambda, s), ...
    'Orientation', mat2cell(theta, s), ...
    'SpatialFrequencyBandwidth', mat2cell(bandwidth, s), ...
    'SpatialAspectRatio', mat2cell(spatialAspectRatio, s), ...
    'Sigma', mat2cell(sigma, s) ...
);
end

function [M, P] = gaborFFT(A, GaborBank, batchSize)

if nargin < 3
    batchSize = 9999; % should be smaller if less available RAM
end

sizeA = size(A);
numFilters = length(GaborBank);
padSize = (maxKernelSize(GaborBank) - 1) / 2;

A = padarray(A, padSize, 'replicate', 'both');
sizeAPadded = size(A);
A_fft = fft2(A);
out = complex(zeros([sizeA numFilters]));

```

```

for f = 1:batchSize:numFilters
    idx = f:min(f + batchSize - 1, numFilters);
    H_batch = zeros([sizeAPadded length(idx)]);

    for k = 1:length(idx)
        H_batch(:, :, k) = ifftshift(makeFDTF(GaborBank(idx(k)),
            sizeAPadded));
    end

    outPadded = ifft2(bsxfun(@times, A_fft, H_batch));

    for k = 1:length(idx)
        out(:, :, idx(k)) = outPadded( ...
            padSize(1) + 1:end - padSize(1), ...
            padSize(2) + 1:end - padSize(2), ...
            k ...
        );
    end

end

M = abs(out);
P = angle(out);
end

function sizeH = maxKernelSize(GaborBank)
    n = numel(GaborBank);
    sigmaX = zeros(n, 1); sigmaY = zeros(n, 1);

    for p = 1:n
        s = GaborBank(p).Sigma;
        sigmaX(p) = s(1);
        sigmaY(p) = s(2);
    end

    rX = ceil(7 * sigmaX);
    rY = ceil(7 * sigmaY);

    maxSize = max(2 * max([rX rY], [], 2) + 1);
    sizeH = [maxSize maxSize];
end

function H = makeFDTF(g, imageSize) %
makeFrequencyDomainTransferFunction
    M = imageSize(1);

```

```

N = imageSize(2);

u = frequencyVector(N);
v = frequencyVector(M);
[U, V] = meshgrid(u, v);

cosTheta = cosd(g.Orientation);
sinTheta = sind(g.Orientation);

Uprime = U .* cosTheta - V .* sinTheta;
Vprime = U .* sinTheta + V .* cosTheta;

sigmauv = 1 ./ (2 * pi * g.Sigma);

sigmauv_sq_inv_1 = 1 / sigmauv(1) ^ 2;
sigmauv_sq_inv_2 = 1 / sigmauv(2) ^ 2;

Uprime = (Uprime - 1 / g.Wavelength);
exponentTerm = Uprime .^ 2 * sigmauv_sq_inv_1 + Vprime .^ 2 *
    sigmauv_sq_inv_2;

A = 2 * pi * g.Sigma(1) * g.Sigma(2);
H = A .* exp(-0.5 * exponentTerm);
end

function u = frequencyVector(N)

    if mod(N, 2)
        u = linspace(-0.5 + 1 / (2 * N), 0.5 - 1 / (2 * N), N);
    else
        u = linspace(-0.5, 0.5 - 1 / N, N);
    end

end

clear all; close all; clc;
warning('off', 'MATLAB:MKDIR:DirectoryExists'); % i know it may exists
mkdir('.out');

imgs = {'dog.jpg', 'katrina.jpg'};
K_values = [2, 3, 4]; % valores de K a testar

figure('Name', 'Originais', 'NumberTitle', 'off');

total = length(imgs);

```



```

for i = 1:total
    I = imread(imgs{i});
    subplot(1, total, i);
    imshow(I);
end

for i = 1:total
    img = imread(imgs{i});
    [~, name, ~] = fileparts(imgs{i});

    figure('Name', [name '- K-means'], 'NumberTitle', 'off');

    for k = 1:length(K_values)
        K = K_values(k);
        seg = segment_kmeans(img, K);

        subplot(2, length(K_values), k);
        imshow(seg, []);
        title(['K-means K = ' num2str(K)]);

        overlay = overlay_labels(img, seg, 0.45);
        subplot(2, length(K_values), length(K_values) + k);
        imshow(overlay);

        record([name '_K.png'], seg, K);
        record([name '_K_Color.png'], overlay, K);
    end

    figure('Name', [name '- Gabor'], 'NumberTitle', 'off');

    for k = 1:length(K_values)
        K = K_values(k);

        seg = segment_gabor(img, K);

        subplot(2, length(K_values), k);
        imshow(seg, []);
        title(['Gabor K = ' num2str(K)]);

        overlay = overlay_labels(img, seg, 0.45);
        subplot(2, length(K_values), length(K_values) + k);
        imshow(overlay);

        record([name '_G.png'], seg, K);
        record([name '_G_Color.png'], overlay, K);
    end
end

```

```

end

function [idx, C] = kmeans(X, k, varargin)
    [n, ~] = size(X);

    rp = randperm(n);
    C = X(rp(1:k), :);

    idx = zeros(n, 1);
    prev_idx = ones(n, 1) * (-1);

    maxIter = 1000;

    for it = 1:maxIter

        D = zeros(n, k);

        for j = 1:k
            diff = X - repmat(C(j, :), n, 1);
            D(:, j) = sum(diff.^2, 2);
        end

        [~, idx] = min(D, [], 2);

        if all(idx == prev_idx)
            break;
        end

        prev_idx = idx;

        for j = 1:k
            pts = X(idx == j, :);
            if isempty(pts)
                C(j, :) = X(randi(n), :);
            else
                C(j, :) = mean(pts, 1);
            end
        end

    end

end

end

function over = overlay_labels(I, labels, alpha)
    I = im2double(I);

```

```

if size(I, 3) == 1
    I = repmat(I, [1 1 3]);
end

pallette = [
    92, 41, 214;
    18, 252, 37;
    235, 88, 75;
    250, 247, 95;
    48, 219, 212;
    224, 152, 75;
    224, 85, 213;
    ] / 255;

labs = labels(:);
[~, ~, newLabs] = unique(labs);
newLabs = reshape(newLabs, size(labels));
K = max(newLabs(:));

if K <= size(pallette, 1)
    colors = pallette(1:K, :);
else
    colors = [pallette; distinguishable_colors(K - size(pallette, 1)
        , pallette)];
end

H = size(labels, 1);
W = size(labels, 2);
C = zeros(H, W, 3);

for k = 1:K
    mask = (newLabs == k);

    for c = 1:3
        ch = C(:, :, c);
        ch(mask) = colors(k, c);
        C(:, :, c) = ch;
    end

end

over = (1 - alpha) * I + alpha * C;
end

function colors = distinguishable_colors(N, avoid_colors)

```

```

if N <= 8
    g = 12;
elseif N <= 16
    g = 16;
else
    g = 22;
end

gridv = linspace(0, 1, g);
[R, G, B] = ndgrid(gridv, gridv, gridv);
P = [R(:) G(:) B(:)];

distance = pdist2(P, avoid_colors);
P = P(all(distance > 0.12345, 2), :);
distance = pdist2(P, avoid_colors);
[~, idx0] = max(min(distance, [], 2));

colors = zeros(N, 3);
colors(1, :) = P(idx0, :);

np = size(P, 1);
active = true(np, 1);
active(idx0) = false;

dmin = pdist2(P, colors(1, :));
dmin(idx0) = Inf;

for k = 2:N
    [~, idx] = max(dmin .* active);

    colors(k, :) = P(idx, :);
    active(idx) = false;

    dnew = pdist2(P, P(idx, :));
    dmin = min(dmin, dnew);
end

end

```


3.3 Resultados Obtidos e Análise

Os resultados obtidos mostram diferenças claras entre os métodos de segmentação baseados em cor (K-means no espaço Lab) e aqueles baseados em textura (filtros de Gabor). Além disso, a variação do número de clusters K influencia diretamente o nível de detalhe das regiões segmentadas.

3.3.1 Imagens originais



(a) Cachorro



(b) Katrina

Figura 10: Imagens originais

3.3.2 Cachorro K-Means




Figura 11: Resultado da aplicação na imagem cachorro

Para o cachorro, o método baseado apenas em cor teve desempenho satisfatório.

- **K = 2:** A segmentação separa de forma nítida o fundo e o cachorro, criando uma divisão simples, porém eficaz. A forma do animal permanece bem definida.
- **K = 3:** Surge uma subdivisão interna do cachorro, separando áreas mais claras e mais escuras das asas. O fundo também é dividido em mais uma região.
- **K = 4:** A segmentação se torna mais rica em detalhes, incluindo nuances de tons tanto no focinho quanto no fundo.

Em geral, o método K-means captou bem as diferenças de cor e luminosidade do cachorro, mesmo sem considerar textura.

3.3.3 Cachorro Gabor + K-Means




Figura 12: Resultado da aplicação na imagem cachorro

Nos resultados baseados em textura, o comportamento muda um pouco.

- **$K = 2$:** A segmentação destaca bastante as bordas e o focinho do cachorro, já que as texturas nessas áreas são mais semelhantes entre si do que com o pelo do cachorro ou o fundo levemente borrado.
- **$K = 3$:** As bordas do cachorro se acentuam ainda mais, e mais uma divisão para separar os olhos e o focinho do resto da imagem.
- **$K = 4$:** As bordas e o focinho continuam bastante demarcados, além de surgir um agrupamento do tronco do animal com o casaco ao fundo da imagem.

O método baseado em Gabor separa bem a silhueta, os olhos e o focinho do cachorro, mas por ignorar a cor acaba agrupando o casaco vermelho com o pelo branco.

3.3.4 Costa K-Means




Figura 13: Resultado da aplicação na imagem costa

Para a zona costeira, que tem pouca saturação, o método ainda assim capta detalhes interessantes.

- **K = 2:** Já é possível perceber a borda entre costa e mar, apesar de agrupar os trechos mais verdes da cidade com o mar.
- **K = 3:** Já é possível distinguir as ruas da cidade. O contorno da costa segue bem acentuado.
- **K = 4:** Trechos com pouca densidade de casas, como o estádio, ou cobertos por nuvens criam um novo agrupamento

O método de cor consegue destacar a costa, as ruas e os trechos mais densamente povoados, apesar de agrupar o mar com parte das casas, por conta da cor semelhante.

3.3.5 Costa Gabor + K-Means




Figura 14: Resultado da aplicação na imagem costa

Com uma imagem com tantos padrões repetidos, o método por textura apresenta resultados bons.

- $K = 2$: A costa, as nuvens e outros trechos com grande variação na frequência são os primeiros a serem agrupados.
- $K = 3$: O mar e as regiões com árvores são agrupados. O mar se torna bastante distinto da costa.
- $K = 4$: O pavimento das estradas maiores é movido para um novo agrupamento

De forma geral, o método baseado em textura retorna bons resultados, extraíndo boas características da imagem.

3.4 Conclusão da Análise

Os experimentos mostram que:

- K-means no espaço Lab produz segmentações mais limpas, estruturadas e visualmente coerentes, destacando corretamente os objetos principais (cachorro).
- O método baseado em textura captura muito bem bordas e regiões lisas.
- A variação de K controla o nível de detalhe: valores baixos criam segmentações mais simples; valores maiores aumentam a granularidade, mas podem introduzir ruído.

Siglas

DCT Discrete Cosine Transform. 2, 3, 9

IDCT Inverse Discrete Cosine Transform. 3

JPEG Joint Photographic Experts Group. 2, 3, 9, 10

PSNR Peak Signal-to-Noise Ratio. 3, 8–11, 15, 16, 19

VQ Vector Quantization. 11, 19